ADVERSARIAL-AI-SECURITY

AI 리스크·적대적 학습 공격·모델 전도

연관 기출 · 130-3-4, 138-1-13, 139-2-1, 131-4-4, 136-1-2

한눈에 이해

모델이 틀릴 수 있다는 품질 문제와 공격자가 데이터·입력·출력을 이용해 의도적으로 실패시키는 위협을 구분합니다.

정의와 핵심 원리

AI리스크는사용맥락에서AI가 야기할 수 있는 피해의가능성과영향입니다. 적대적ML은 공격자의목표·지식·능력·생애주기위치에따라 오염·회피·기밀추론·모델 탈취·오용등을 분석합니다.

• 학습 단계poisoning은 데이터·라벨·모델 업데이트등을 조작해전체성능저하나조건부백도어를유도합니다. 추론 단계evasion은 입력을 조작해오분류·우회를노립니다. model extraction은 질의·응답등으로기능을 복제하고 membership inference는 특정 기록의 학습 참여 여부를추정합니다. 기출의4분류는 분류축을먼저 명시합니다.

• 모델 전도/model inversion은 출력·파라미터등에서입력 특성이나 민감 자료를 추론·복원하는공격입니다. 전도 결과가 항상 특정 개인의실제 원본과 일치한다는뜻은아닙니다. 접근제한·출력 정밀도/질의량·DP·학습 최소화·공격 평가를 상황에 맞게적용합니다.

• 보안 위험은 오염·탈취·프롬프트주입·권한남용, 프라이버시 위험은 학습 자료·입출력 누출·재식별, 사회 위험은 차별·허위정보·조작·의존·권력집중등으로구분합니다. provenance·검증집합·강건성평가·데이터정제·접근 분리·운영 감시와 피해 구제를전생애주기에 연결합니다.

• 파운데이션 모델 구현에서는 학습 자료·출력의 개인정보와 지식재산권 및 적용되는 이용조건을 검토합니다. 학습·미세조정·추론의 전력·물 사용과 환경영향을 측정하거나 추정하고, 편향·허위정보·접근격차 등 사회적 영향을 평가합니다. 모델의 개념·특징·기반기술은 파운데이션·언어·멀티모달 모델의 정의와 핵심 원리를 함께 확인합니다. 이는 운영상 검토 방향이며 개별 법적 결론이 아닙니다.

구조·비교·판단

구분	핵심 원리	적용·한계
오염	학습 자료·업데이트변조	출처·검증·강건 집계
회피	추론 입력조작	위협 모델·강건성·입력 통제
프라이버시 공격	참여·특성·원문 추정	출력·질의·DP·수집제한

적용 예제

고객분류 모델의 누출 평가

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 확률벡터를무제한공개하는API 가정

1. 공격자가어떤출력·지식·질의량을얻는지정의합니다.
2. 회원추론·전도·추출을별도로시험하고 실제 원본일치여부를검증합니다.
3. 필요이상의출력·반복질의와 접근 권한을 줄입니다.
4. 유용성저하와잔여위험을 측정하며 모니터링합니다.

결과·해석: 공격 목표·관측·방어효과를 분리하고 단일방어의한계를 기록합니다.

전제·주의: 공격 분류는 문헌별로 다릅니다.방어가특정 위협 모델밖에서도완전보호한다는보장은없습니다.

답안 골격과 혼동 방지

리스크범주 → 공격생애주기도 식 → 4공격비교 → 전도·회원추론구분 → 다층대응

- 모든 AI오류를 적대적공격이라 하지 않습니다.
- 전도와 모델 파라미터추출을동일시하지 않습니다.

내용을 가리고 회상

1. 오염과 회피는 어느단계가 다릅니까?
2. 회원추론과 전도는 무엇을알아내려합니까?
3. 보안·프라이버시·사회적위험을 한사례에서 구분하십시오.

적용 기준과 근거

명시한 출처 판본의 원리를 설명하며 제품별 구현 차이는 별도 확인합니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- NIST AI100-2e2025: Adversarial Machine Learning - Apostol Vassilev et al. / NIST; 2025-03; 확인 2026-11-05.
- NIST AI600-1 Generative AI Profile - NIST; 2024-07; 확인 2026-11-05.
- NIST AI100-1: AI RMF1.0 - NIST; 2023-01; 확인 2026-11-05.