AI-ACCELERATOR-MEMORY

AI 가속기·HBM·CXL·뉴로모픽 칩

연관 기출 · 128-1-9, 134-1-12, 136-1-8, 138-2-3, 129-4-3, 127-2-4

한눈에 이해

AI 속도는 계산기 수뿐 아니라 데이터가 계산기까지 오는 길과, 잘 맞는 연산 형태에 달려 있습니다.

정의와 핵심 원리

GPU는 대규모 병렬 연산을 수행하는 프로세서이고 TPU는 Google이 행렬 중심 ML 워크로드를 위해 설계한 ASIC입니다. HBM은 패키지 가까이에 높은 대역폭의 적층 메모리를 두고, CXL은 CPU와 연결 장치 사이의 일관성 있는 메모리 접근을 지원합니다.

• GPU의 SIMT·행렬가속기는범용병렬생태계와 다양한연산에 유리합니다.TPU는 행렬연산용구조와 XLA 컴파일을활용하며 형상·연산 지원·배치크기·입출력 병목에 따라 효율이달라집니다.TPU가 항상 GPU보다 빠르거나저렴하다는일반 화는부적절합니다.

• HBM은 넓은인터페이스와적층연결로 대역폭을 높여가중치·활성값이 동병목을 줄입니다.CXL은 PCIe 물리기반 연결에 서 cache·memory프로토콜로 확장·공유를돕지만장치유형·버전·지연·RAS·격리를검토해야합니다.HBM 대체와 원격메모리를 동일시하지 않습니다.

• 뉴로모픽칩은SNN의 희소한스파이크 이벤트를 활용하고 메모리와 연산을 가깝게결합합니다.시간 정보·저전력엣지작업에 잠재력이있지만학습 방법·정확도·도구·워크로드적합성이과제입니다.반도체가치사슬은 설계/IP → 제조 → 패키징·시험 → 시스템으로 구분합니다.

구조·비교·판단

구분	핵심 원리	적용·한계
GPU	병렬·행렬연산과 넓은생태계	다양한모델·메모리 병목
TPU	ML특화ASIC·XLA	지원 연산·배치·입출력 검토
HBM/CXL	근접 대역폭/일관성연결	용량·비용·지연 절충
뉴로모픽	이벤트 기반 SNN	실측전력·품질동시평가

적용 예제

가속기 선정 실험

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 같은 모델과 목표 정확도;학습/추론을 분리

1. 지원 연산·정밀도·모델 메모리와 배치크기를고정합니다.

2. GPU와 TPU의 처리량·p95지연·총비용·전력을 동일 조건으로 측정합니다.

3. 계산이 아닌데이터로 딩·AllReduce·메모리 대역폭이 병목인지프로파일링합니다.

4. 필요시HBM 용량·네트워크·CXL확장의효과를 따로평가합니다.

결과·해석: 명목TOPS대신 요구 품질을 만족하는시스템전체 효율로선택합니다.

전제·주의: 제품수치와버전은 변동합니다.비메모리 산업성장정책의 현행수치·정부전략은이토픽에서미확인입니다.

답안 골격과 혼동 방지

연산·메모리 병목 → GPU/TPU비교 → HBM/CXL 구조 → 뉴로모픽특성 → 측정 기반선정

- HBM을 CPU 캐시라고쓰지않습니다.
- CXL 연결이 로컬DRAM과 같은 지연이라 고보장하지 않습니다.

내용을 가리고 회상

1. 행렬특화가유리하지 않은작업은 무엇입니까?

2. HBM과 CXL이 해결하는문제는 어떻게다릅니까?

3. 뉴로모픽의희소이벤트가 전력과 어떻게연결됩니까?

적용 기준과 근거

명시한 출처 판본의 원리를 설명하며 제품별 구현 차이는 별도 확인합니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Introduction to Cloud TPU - Google Cloud; 상시 문서; 확인 2026-11-05.
- Neuromorphic Computing and Engineering - Intel Labs; 상시 문서; 확인 2026-11-05.
- About CXL - CXL Consortium; 상시 문서; 확인 2026-11-05.