AI-DATA-CENTER-PLATFORM

AI 데이터센터·슈퍼컴퓨팅·DCI·입지·규모산정

연관 기출 · 134-2-4, 134-4-2, 139-4-3, 140-2-4, 140-4-6, 133-2-1

한눈에 이해

AI 데이터 센터의 실제 처리량은 GPU뿐 아니라 메모리·통신·전력·냉각에 따라 달라집니다.

정의와 핵심 원리

AI 데이터 센터는 대규모 AI 학습·추론을 위한 가속기·고속 망·저장·전력·냉각·운영 체계를 통합한 시설입니다. AI 슈퍼 컴퓨팅 플랫폼은 이 자원을 워크로드 스케줄링·분산 학습·개발 도구와 연결하여 제공하는 시스템입니다.

• 학습은 가속기 간 AllReduce·모델·파이프라인 병렬 통신과 체크포인트 I/O가 병목이 되기 쉽습니다. HBM·GPU 간 링크·RDMA 네트워크·병렬 스토리지·데이터 캐시·스케줄러·관측을 함께 설계합니다. 추론은 토큰 처리량·첫 토큰 지연·동시성·KV 캐시·배치 처리의 장단점을 측정합니다.

• 전통 HPC는 범용 과학 계산과 정밀도 요구, 클라우드는 탄력적 서비스 제공, AI 플랫폼은 텐서 연산과 대규모 학습·추론이 주요 강점입니다. 서로 배타적인 분류는 아닙니다. 고밀도 랙은 전력 공급·UPS·배전·액체 냉각·열 관리·소방·유지 보수 동선을 요구합니다.

• DCI는 센터 간 데이터·서비스 연결로 광 전송·라우팅·암호화·대역·지연·경로 다양성을 고려합니다. 입지는 지진·홍수·전쟁·전력·통신·물·인력·규제·거리별 공통 재난을 분석합니다. 규모는 업무량·동시성·성능 측정·성장·장애 시 잔여 용량으로 산정하며 공식 TTA 산식은 판본 원문 확인이 필요합니다.

구조·비교·판단

구분	핵심 원리	적용·한계
전통 HPC	과학 계산·정밀도·MPI	문제별 메모리·통신
클라우드	서비스·탄력·과금	제공 계층·책임·비용
AI 플랫폼	텐서·분산 학습·추론	가속기·HBM·데이터·전력

적용 예제

지역 상실을 가정한 AI 서비스

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 같은 용량의 두 센터가 평소 각각 40%를 사용합니다. 한 센터 전체가 멈출 때를 대비합니다.

1. 남은 한 센터가 평소 두 센터의 수요를 모두 받으면 부하가 80%가 됩니다. 연산·망·전력이 이 부하를 감당하는지 검증합니다.

2. 학습 배치는 중단 가능성·체크포인트 시점으로 재개 전략을 둡니다.

3. 추론 서비스를 다른 센터로 돌릴 때 모델 복제와 캐시 준비에 필요한 시간, 트래픽 우회 지연을 측정합니다.

4. 두 센터가 같은 변전소·통신 관로·재난 권역에 의존하는지 확인합니다.

결과·해석: 명목 장비 수보다 실제 종단 성능과 장애 후 수용력을 확인합니다.

전제·주의: NVIDIA 설계 가이드에 접속하지 못했고 TTA 0292/R3 전문도 확인이 남아 있습니다. 규모 산정 계수, 의무 입지 거리, 개별 제품 수치는 확인하지 못했습니다.

답안 골격과 혼동 방지

도입 배경 → 구성 요소 → 세 플랫폼 비교 → 네트워크·DCI → 입지·가용성·규모 산정

- 대역폭과 지연을 동일지표로 쓰지않습니다.
- 두 센터면 공통 재난이 없다고 가정하지 않습니다.

내용을 가리고 회상

1. AllReduce 통신 병목은 왜중요합니까?

2. 고밀도 전력과 냉각은 어떻게 연결됩니까?

3. 재해 복구 센터 입지에 거리 하나만 쓰면 왜 부족합니까?

적용 기준과 근거

명시한 출처 판본의 원리를 설명하며 제품별 구현 차이는 별도 확인합니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Introduction to Cloud TPU - Google Cloud; 상시 문서; 확인 2026-11-05.
- About CXL - CXL Consortium; 상시 문서; 확인 2026-11-05.
- Disaster recovery options in the cloud - AWS; 상시 백서; 확인 2026-11-05.