AI-DATA-CENTER-PLATFORM

AI 데이터센터·슈퍼컴퓨팅·DCI·입지·규모산정

연관 기출 · 134-2-4, 134-4-2, 139-4-3, 140-2-4, 140-4-6, 133-2-1

한눈에 이해

GPU를 많이 놓는 것만으로 AI센터가 되지 않으며 계산·메모리·통신·전력·냉각이 함께 지속 처리량을 결정합니다.

정의와 핵심 원리

AI데이터센터는대규모AI학습·추론을 위한가속기·고속망·저장·전력·냉각·운영체계를통합한시설입니다. AI슈퍼컴퓨팅플랫폼은 이자원을 워크로드스케줄링·분산학습·개발 도구와 연결하여 제공하는 시스템입니다.

• 학습은 가속기간AllReduce·모델/파이프라인병렬통신과 체크포인트I/O가 병목이 되기쉽습니다. HBM·GPU간링크·RDMA네트워크·병렬스토리지·데이터 캐시·스케줄러·관측을함께 설계합니다. 추론은 토큰 처리량·첫토큰 지연·동시성·KV캐시·배치절충을 측정합니다.

• 전통HPC는 범용과학계산과 정밀도요구, 클라우드는 탄력적서비스제공, AI플랫폼은 텐서연산과 대규모 학습·추론이 주요 강점입니다. 서로 배타적인분류는 아닙니다. 고밀도랙은전력공급·UPS·배전·액체냉각·열관리·소방·유지보수동선을요구합니다.

• DCI는 센터간데이터·서비스 연결로 광전송·라우팅·암호화·대역·지연·경로다양성을고려합니다. 입지는 지진·홍수·전쟁·전력·통신·물·인력·규제·거리별공통 재난을 분석합니다. 규모는 업무량·동시성·성능 측정·성장·장애시잔여용량으로 산정하며 공식TTA산식은판본 원문 확인이 필요합니다.

구조·비교·판단

구분	핵심 원리	적용·한계
전통HPC	과학계산·정밀도·MPI	문제별메모리·통신
클라우드	서비스·탄력·과금	제공 계층·책임·비용
AI플랫폼	텐서·분산학습·추론	가속기·HBM·데이터·전력

적용 예제

지역 상실을 가정한 AI 서비스

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 2센터평시각40%부하;한센터전체 중단대비

1. 한센터에서전체80%를수용할 수 있는 지연산·망·전력을 검증합니다.

2. 학습배치는중단가능성·체크포인트시점으로 재개전략을둡니다.

3. 추론은 모델 복제·캐시워밍·트래픽 우회지연을 측정합니다.

4. 두센터가같은 변전소·통신관로·재난권역에의존하는지확인합니다.

결과·해석: 명목 장비 수보다실제 종단성능과 장애후수용력을확인합니다.

전제·주의: NVIDIA설계가 이드접근실패·TTA0292/R3전문 미열람.구체규모계수·의무입지거리·제품숫자는미확인입니다.

답안 골격과 혼동 방지

등장배경 → 구성 요소도식 → 세플랫폼비교 → 네트워크·DCI → 입지·가용성·산정

- 대역폭과 지연을 동일지표로 쓰지않습니다.
- 두센터면공통 재난이 없다고가정하지 않습니다.

내용을 가리고 회상

1. AllReduce의통신 병목은 왜중요합니까?

2. 고밀도전력과 냉각은 어떻게연결됩니까?

3. 재해센터입지에거리하나만쓰면왜부족합니까?

적용 기준과 근거

명시한 출처 판본의 원리를 설명하며 제품별 구현 차이는 별도 확인합니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Introduction to Cloud TPU - Google Cloud; 상시 문서; 확인 2026-11-05.
- About CXL - CXL Consortium; 상시 문서; 확인 2026-11-05.
- Disaster recovery options in the cloud - AWS; 상시 백서; 확인 2026-11-05.