AI-TRAINING-DATA-QUALITY

AI 학습데이터 생애주기·품질·어노테이션

연관 기출 · 126-3-6, 128-2-1, 131-3-1, 134-1-6, 139-3-6, 140-2-3

한눈에 이해

이미지 수가 많아도 밤 장면이 없거나 사람 경계가 잘못 표시되면 야간 탐지기가 실패합니다. 파일 형식이 맞는지, 라벨 뜻이 맞는지와 실제 모델 과업에 도움이 되는지를 함께 검사해야 합니다.

정의와 핵심 원리

AI 과업에 필요한 원천자료·정제자료·라벨·데이터셋의 적합성과 구축 과정을 전 생애주기에 걸쳐 측정·보증·개선하는 활동입니다.

• 특성은 목적 의존성·분포/대표성·다양성·비정형/다중모달·원천-라벨 연계와 정답의 불확실성입니다. 계획→수집/획득→정제→가공/라벨→검수/학습 검증→공개/운영→활용 피드백으로 관리합니다. train/validation/test 분리와 사람·장소·시간 단위의 중복 누출 방지가 필요합니다.

• 품질은 목적 적합·정확 라벨·중복/손상 제거·유효성과 지속 개선·역할/교육을 연결합니다. 검사 지표는 다양성/분포·구문(스키마·타입·범위)·의미정확성(참값·경계/클래스)·모델 유효성으로 나눕니다. 지표 이름·산식·분모·허용치·표집방법을 과업과 버전별로 정합니다.

• 이미지는 classification·bounding box·polygon/segmentation·keypoint, 음성은 전사/화자/구간, 텍스트는 개체/관계/감정 등 방식이 있습니다. 라벨 지침·gold set·이중 라벨·전문가 조정·버전 이력을 두고 오류를 원천 단계까지 환류합니다. NIA v1.0의 실제 확인 내용과 128회 지정 v2.0의 미열람 세부는 구분합니다.

구조·비교·판단

구분	원리·특징	적용·주의
구문	JSON 구조·자료형·범위	자동 검사 가능 범위 큼
의미	클래스·경계·전사 참값	전문가·일치도·샘플 검수
유효성·대표성	모델 과업·집단 분포	라벨 정확성만으로 불충분

적용 예제

보행자 박스 라벨 검수

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 100개 이미지에 참값 보행자120명, 예측 라벨110개 중 올바른 클래스·위치100개입니다.

1. 정의한 IoU 임계·매칭 규칙 아래 TP100, FP10, FN20으로 셉니다.

2. 라벨 precision=100/110≈90.91%, recall=100/120≈83.33%입니다.

3. 밤/비/가림 집단별 누락을 따로 보고 라벨 지침 수정·재검수 후 holdout 모델 성능을 확인합니다.

결과·해석: 형식 통과와 의미 정확성·대표성·모델 유효성을 별개로 측정합니다.

전제·주의: 지표 임계값은 예제 가정이며 모든 AI 데이터의 공식 합격 기준이 아닙니다.

답안 골격과 혼동 방지

정의·특성 → 생애주기·원칙 → 품질 모델·지표·분모 → 수집/정제/라벨 방식 → 검수·학습·피드백

- annotator 간 일치가 높아도 모두 같은 잘못된 지침을 따를 수 있습니다.
- v1.0 항목을 지정 v2.0과 대조 없이 동일 목록으로 외우지 않습니다.

내용을 가리고 회상

1. 구문과 의미정확성의 검사는 어떻게 다릅니까?

2. 원천자료·라벨·가공 이력을 어떻게 연결합니까?

3. 정확한 라벨만 있는데 특정 환경 성능이 나쁜 이유는 무엇입니까?

적용 기준과 근거

NIA v1.0 본문 pp.11~20·86~89 실제 확인. v2.0 공지/수정일은 읽었으나 첨부는 정상 접근 거부로 미열람하여 128회 지정판의 모델·지표 세부 동일성을 확정하지 않습니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- 인공지능 학습용 데이터 품질관리 가이드라인 v1.0 제1권 - 한국지능정보사회진흥원·과학기술정보통신부; 2021-02, v1.0; 확인 2026-11-05.
- 인공지능 학습용 데이터 품질관리 가이드라인 v2.0 공개 - 한국지능정보사회진흥원; 2022-02-22 게시, 2022-10-05 수정판 안내; 확인 2026-11-05.
- scikit-learn: Metrics and scoring - scikit-learn developers; 1.9.1 표시; 확인 2026-11-05.