DECISION-TREE-ENSEMBLES

의사결정나무·지니/엔트로피·배깅/부스팅

연관 기출 · 126-1-8, 126-3-4, 130-3-1

한눈에 이해

질문을 순서대로 나누어 고객을 분류하는 것이 나무입니다. 한 나무의 판단이 불안정하면 여러 나무를 독립적으로 합치거나 이전 오차를 순서대로 보완할 수 있습니다.

정의와 핵심 원리

의사결정 나무는 특징 조건으로 표본 공간을 반복 분할하는 모델이며 앙상블은 여러 모델의 예측을 결합하여 일반화를 개선하는 방법입니다.

• 한 노드의 클래스 비율이 p_k이면 지니 불순도는 $Gini=1-\Sigma p_k^2$, 엔트로피는 $Entropy=-\Sigma p_k \log_2 p_k$입니다. 한 클래스만 있으면 둘 다 0입니다. 두 클래스가 절반씩이면 각각 0.5와 1입니다. 부모의 불순도에서 자식의 가중 평균 불순도를 뺍니다. 그 감소량이 큰 분할을 고릅니다.

• 나무는 조건 해석·비선형 상호작용에 유리하지만 작은 자료 변화에 구조가 바뀌고 깊어질수록 과적합할 수 있습니다. max_depth·min_samples_leaf·pruning 등으로 제한하고 검증으로 정합니다. 탐욕적 분할이 전체 최적 나무를 보장하지는 않습니다.

• Bagging은 bootstrap 표본별 모델을 병렬적으로 학습해 평균/투표하여 분산을 줄이고 OOB 자료로 점검할 수 있습니다. Boosting은 오분류 가중치 또는 손실의 음의 gradient를 순서대로 보완합니다. Random Forest는 bagging에 분할 특징 무작위성을 더하며 boosting의 학습률·반복 수와 잡음 민감도를 별도로 관리합니다.

구조·비교·판단

구분	원리·특징	적용·주의
단일 나무	하나의 분할 규칙 집합	해석 쉽지만 불안정
Bagging·RF	재표집 모델의 평균/투표	분산 감소·병렬화
Boosting	이전 오차/gradient 순차 보정	학습률·과적합·잡음 관리

적용 예제

분할 불순도 계산

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 부모 표본4개는 양성2·음성2이고, 분할 후 왼쪽 양성2·오른쪽 음성2입니다.

1. 부모 Gini=$1-(2/4)^2-(2/4)^2=0.5$, Entropy=$-2\times0.5\log_2 0.5=1$입니다.

2. 두 자식은 순수하므로 Gini/Entropy가0이고 가중 불순도도 $(2/4)\times0+(2/4)\times0=0$입니다.

3. 분할로 줄어든 지니 불순도는 0.5, 엔트로피는 1입니다.

결과·해석: 두 불순도는 범위가 다르지만 같은 분할 전후 원리로 계산합니다.

전제·주의: 순수 분기 하나를 찾았다고 시험 데이터 성능이 완벽하다는 뜻은 아닙니다.

답안 골격과 혼동 방지

나무 구조·학습 흐름 → 불순도 식·가중 분할 → 깊이·가지치기 → 배깅/부스팅 비교 → 데이터·목적별 선택

- 자식 불순도를 표본수 가중 없이 단순 합산하지 않습니다.
- 모든 boosting이 AdaBoost의 가중치 갱신만 쓴다고 쓰지 않습니다.

내용을 가리고 회상

1. 이진 균등 노드의 Gini와 Entropy는 얼마입니까?

2. 배깅과 부스팅의 학습 순서는 어떻게 다릅니까?

3. Random Forest가 나무 간 상관을 줄이는 방법은 무엇입니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- scikit-learn: Decision Trees - scikit-learn developers; 1.9.1 표시; 확인 2026-11-05.
- scikit-learn: Ensembles - scikit-learn developers; 1.9.1 표시; 확인 2026-11-05.