DIFFERENTIAL-PRIVACY

차분 프라이버시와 프라이버시 예산

연관 기출 · 138-4-6

한눈에 이해

한 사람의 포함 여부가 발표 결과를 크게 바꾸지 않게 만들어 참여자의 추가 노출을 제한합니다.

정의와 핵심 원리

차분 프라이버시(DP)는 한 사람의 기록 포함 여부만 다른 인접 데이터셋을 비교해, 확률적 알고리즘의 출력 분포가 얼마나 달라질 수 있는지 제한하는 정의입니다. ε는 출력 확률의 차이를 제한하는 배율에 관여하고, (ε, δ)-DP의 δ는 확률 상한에 더하는 여유입니다.

• 순수 ε-DP는 모든 출력 사건 S에 대해 $Pr[M(D)\in S] \le \exp(\varepsilon) Pr[M(D')\in S]$를 요구합니다. 같은 조건에서는 ε가 작을수록 허용하는 차이가 작아져 보호가 강해집니다. 대신 잡음이 커져 결과의 유용성이 떨어질 수 있습니다. ε는 재식별 확률이나 출력 오차율과 구분합니다.

• 질의 민감도는 한 기록의 변경으로 결과가 달라질 수 있는 최대 크기입니다. 라플라스 기법은 일반적으로 척도 $\Delta f/\varepsilon$의 잡음을 더합니다. 합계 질의에서 개인의 값을 제한하지 않으면 민감도가 무한히 커질 수 있으므로 인접성의 정의와 값의 범위를 밝힙니다.

• 질의를 반복하면 결과에서 얻는 정보가 쌓이므로 프라이버시 예산을 관리합니다. 순수 ε-DP의 기본 순차 합성 상한은 각 ε의 합입니다. 추가 원자료를 보지 않고 출력만 가공하면 보호가 약해지지 않습니다. 중앙형은 신뢰하는 집계자가 원자료를 처리하고, 로컬형은 각 단말이 값을 바꾼 뒤 전송합니다.

구조·비교·판단

구분	핵심 원리	적용·한계
중앙 DP	신뢰하는 집계자가 원자료 처리	집계자 신뢰와 접근 통제 필요
로컬 DP	각 단말에서 값을 무작위로 바꿔 전송	집계자에게 원자료를 주지 않음, 오차 증가 가능
출력 관리	예산·민감도·질의 횟수 관리	예산 계산과 결과 유용성 확인

적용 예제

인원수 질의의 잡음 척도

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 개인당 기록 한 건이며, 인접 데이터셋은 한 사람의 기록이 있거나 없는 경우입니다. 인원수를 세는 질의의 민감도는 1입니다.

1. ε = 0.5이면 라플라스 분포의 척도 b = 1/0.5 = 2입니다.

2. 2는 잡음 분포의 척도입니다. 실제로 더하는 값은 호출할 때마다 달라질 수 있습니다.

3. 같은 데이터셋에 ε = 0.5인 질의를 세 번 실행하면 기본 순차 합성 상한은 1.5입니다.

4. 필요한 정확도, 표본 수, 발표 정책을 바탕으로 예산을 나눕니다.

결과·해석: DP는 결과에서 개인의 포함 여부를 얼마나 구분할 수 있는지 제한합니다. 실제 오차와 공개 횟수는 별도로 관리합니다.

전제·주의: 인원수 질의와 기본 합성을 설명하는 예제입니다. 학습 알고리즘에 DP를 적용하려면 인접성과 보호 조건을 별도로 확인해야 합니다.

답안 골격과 혼동 방지

인접성·정의식 → ε와 δ의 의미 → 민감도와 라플라스 잡음 → 합성과 예산 → 중앙·로컬 신뢰 모형

- ε를 익명성을 보장하는 백분율로 해석하지 않습니다.
- 잡음을 더한 뒤에도 DP의 정의식이 성립하는지 확인해야 합니다.

내용을 가리고 회상

1. 민감도는 무엇이 변할 때의 최대 변화량입니까?

2. 질의를 여러 번 하면 프라이버시 예산을 더 사용하는 이유는 무엇입니까?

3. 합계를 구할 때 개인별 값의 범위를 정해야 하는 이유는 무엇입니까?

적용 기준과 근거

명시한 출처 판본의 원리를 설명하며 제품별 구현 차이는 별도 확인합니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- The Algorithmic Foundations of Differential Privacy - Cynthia Dwork; Aaron Roth; 2014; 확인 2026-11-05.