DIMENSIONALITY-REDUCTION

차원 축소: 특징 선택과 투영

연관 기출 · 131-1-5

한눈에 이해

비슷한 측정값을 여러 열에 넣으면 같은 정보가 반복되고 거리 비교가 어려워질 수 있습니다. 필요한 열만 고르거나 여러 열을 새 축으로 요약합니다. 줄인 뒤에도 과업에 필요한 정보가 남는지 확인합니다.

정의와 핵심 원리

원 자료의 중요한 변동·구조 또는 예측 정보를 보존하면서 특징의 수나 표현 차원을 줄이는 변환입니다.

• 특징 선택은 원 컬럼 일부를 남기고 추출은 PCA·SVD·autoencoder처럼 새 좌표를 만듭니다. 저장/학습 비용·공선성·잡음·시각화에 도움을 줄 수 있지만 희소한 판별 신호를 잃을 수도 있어 독립 검증 성능을 봐야 합니다.

• PCA는 중심화한 자료의 분산이 큰 직교 축을 차례로 찾는 선형 투영입니다. 공분산 고유값 λ_j의 합 대비 상위 성분 합이 설명 분산 비율입니다. 단위가 다른 특징은 scale 영향을 검토하며 큰 분산이 정답과 관련된 정보라는 보장은 없습니다.

• Kernel PCA·manifold 방법은 비선형 구조를, autoencoder는 재구성 가능한 잠재 표현을 학습합니다. 시각화에서 점이 분리되었다고 원 공간의 군집·인과를 증명하지 않습니다. 변환기는 학습셋에만 fit하고 동일 변환을 검증/시험/운영 자료에 적용하며 축 해석·재현성·새 데이터 변환 지원을 확인합니다.

구조·비교·판단

구분	원리·특징	적용·주의
선택	원 특징 일부 보존	해석·수집 비용 축소
PCA/SVD	선형 축으로 투영	분산·scale·정보 손실
비선형 추출	곡면/재구성 구조	비용·해석·검증 필요

적용 예제

완전 중복된 두 특징

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 중심화·표준화한 두 특징의 공분산이 [[1,1],[1,1]]입니다.

1. 고유값은 2와 0이고 첫 주축은 (1,1)/√2입니다.

2. 첫 주성분 점수는 z=(x1+x2)/√2입니다. 첫 축이 설명하는 분산의 비율은 2/(2+0)=100%입니다.

3. 이 예제의 두 열은 같은 정보를 담으므로 한 차원으로 줄여도 분산 손실이 없습니다. 실제 자료에서는 남긴 성분으로 과업을 수행할 때 성능도 확인합니다.

결과·해석: 고유값·새 축·설명 분산의 관계를 작은 행렬로 이해할 수 있습니다.

전제·주의: 실제 분류 문제에서 설명 분산100%에 가까움만으로 성능을 보장하지 않습니다.

답안 골격과 혼동 방지

필요성·선택/추출 → PCA 단계 → 성분수·설명 분산 → 2×2 예제 → 누출·해석·과업 검증

- 차원 축소와 단순 행 표본추출을 혼동하지 않습니다.
- 시험셋까지 포함하여 PCA를 fit하지 않습니다.

내용을 가리고 회상

1. 특징 선택과 PCA는 원 컬럼을 어떻게 다룹니까?

2. 고유값2·0에서 첫 성분 설명 분산은 얼마입니까?

3. 분산이 작은 성분도 예측에 중요할 수 있습니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- scikit-learn: Decomposing signals in components - scikit-learn developers; 1.9.1 표시; 확인 2026-11-05.