FEDERATED-LEARNING-SECURITY

연합학습·FedAvg와 프라이버시 보완

연관 기출 · 128-3-6

한눈에 이해

원자료는 각 장치에 남기고 모델의 변경값만 모읍니다. 변경값에서도 학습에 사용한 정보가 드러날 수 있어 별도의 보호가 필요합니다.

정의와 핵심 원리

연합학습은 여러 클라이언트가 각자 보유한 데이터로 모델을 학습한 뒤, 변경값을 모아 공유 모델을 개선하는 방식입니다. FedAvg는 참여한 클라이언트의 모델 값을 표본 수에 따라 가중 평균합니다.

• 서버가 초기 모델과 참여자를 정합니다. 모델 배포 → 각 클라이언트에서 학습 → 변경값 전송 → 집계의 과정을 반복합니다. 원자료를 중앙으로 옮기는 부담이 줄지만, 서버와 클라이언트를 어디까지 신뢰할지와 업무상 처리 근거는 확인해야 합니다.

• 데이터 분포가 서로 다르거나(Non-IID) 표본 수가 고르지 않으면 수렴과 공정성이 달라질 수 있습니다. 장치 성능, 통신 비용, 연결이 끊기거나 응답이 늦는 장치도 영향을 줍니다. FedSGD는 기울기를 자주 집계합니다. FedAvg는 각 장치가 여러 번 갱신한 모델을 평균해 통신 횟수를 줄일 수 있습니다. FedProx 등 변형은 각 원문에서 목적과 동작을 확인합니다.

• 변경값에서 기울기를 역추정하거나, 특정 표본이 학습 데이터에 포함됐는지 추정하는 멤버십 추론(membership inference)이 가능합니다. 악성 클라이언트가 백도어를 심을 수도 있습니다. 안전한 집계(secure aggregation)는 개별 변경값의 노출을 줄이고, 차분 프라이버시(DP)는 출력에 대한 한 사람의 영향을 제한합니다. 동형암호(HE)와 다자간 계산(MPC)은 계산의 기밀성을 높이는 데 쓰입니다. 클라이언트 인증, 강건한 집계와 감사도 함께 검토합니다.

구조·비교·판단

구분	핵심 원리	적용·한계
중앙 학습	원자료를 한곳에 모아 학습	데이터 이동과 접근 권한
FedAvg	각 장치에서 학습한 뒤 가중 평균	데이터 분포 차이, 통신과 참여자 이탈
보호 기술	안전한 집계·DP·HE·MPC	정확도·공모·성능의 장단점

적용 예제

데이터 수에 따른 가중 평균

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: A에는 표본 100개가 있고 학습한 모델의 값은 2입니다. B에는 표본 300개가 있고 모델의 값은 4입니다. 모델 값이 하나인 예제입니다.

1. 전체 표본은 400입니다.

2. 표본 수를 가중치로 쓴 집계값은 (100 × 2 + 300 × 4) / 400 = 3.5입니다.

3. 클라이언트별 값에 같은 비중을 주면 (2 + 4) / 2 = 3입니다.

4. 표본의 불균형이나 악성 변경값이 집계 결과를 얼마나 바꾸는지 평가합니다.

결과·해석: 표본이 많은 B가 집계값에 더 큰 영향을 줍니다. 이 계산만으로 기밀성·강건성·공정성을 판단할 수는 없습니다.

전제·주의: 가중 평균의 원리를 설명하는 예제입니다. 가중치와 참여 정책은 알고리즘마다 다를 수 있습니다.

답안 골격과 혼동 방지

학습 라운드의 흐름 → 알고리즘 비교 → 데이터 분포와 통신 → 정보 유출과 오염 → 보호 기술

- 원자료를 보내지 않아도 모델 변경값에서 정보가 드러날 수 있습니다.
- 변경값을 암호화해 집계해도 악성 입력을 막는 검증은 필요합니다.

내용을 가리고 회상

1. FedAvg에서 표본 수를 가중치로 쓰는 이유는 무엇입니까?

2. 원자료를 보내지 않아도 모델 변경값에서 무엇을 추론할 수 있습니까?

3. 안전한 집계와 차분 프라이버시는 각각 어떤 위험을 줄입니까?

적용 기준과 근거

명시한 출처 판본의 원리를 설명하며 제품별 구현 차이는 별도 확인합니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Communication-Efficient Learning of Deep Networks from Decentralized Data - H. Brendan McMahan et al. / Google;AISTATS; 2017; 확인 2026-11-05.
- NIST AI100-2e2025: Adversarial Machine Learning - Apostol Vassilev et al. / NIST; 2025-03; 확인 2026-11-05.