FEDERATED-LEARNING

연합학습의 FedAvg와 분산 최적화

연관 기출 · 128-3-6

한눈에 이해

여러 기관이 원자료를 한곳에 모으기 어려워도 각자 자료에서 모델을 학습하고 업데이트를 합칠 수 있습니다. 다만 원본을 안 보냈다는 사실만으로 업데이트에서 정보가 새지 않는다는 보장은 없습니다.

정의와 핵심 원리

여러 참여자가 로컬 자료를 유지한 채 모델 업데이트를 교환하여 공동 모델을 학습하는 분산 학습 방법입니다.

• 서버가 초기 모델을 정해 참여자에게 보냅니다. 각 참여자는 자기 데이터로 모델을 학습해 갱신값을 보냅니다. FedAvg는 그 라운드에 참여한 n_k개 표본의 모델 w_k를 w=Σ(n_k/Σn_j)w_k로 가중 평균합니다. 모델 구조와 파라미터의 위치가 같아야 합니다.

• FedSGD는 참여자가 계산한 기울기를 모읍니다. FedAvg는 각 참여자가 여러 번 갱신한 뒤 모델을 합쳐 통신 라운드를 줄일 수 있습니다. 기관마다 데이터 분포와 표본 수가 다르고 이탈이나 응답 지연이 생기면 수렴과 기관별 성능에 차이가 날 수 있습니다. 참여 방식, 서버 최적화, 정규화와 개인화를 검토합니다.

• 집계 업데이트도 정보 유출·오염 가능성이 있어 secure aggregation·차분 프라이버시·암호 기술·검증을 별도로 검토합니다. secure aggregation은 개별 업데이트를 숨기는 역할이고 DP는 출력/학습 과정의 기여 정보 제한을 목표로 하며 정확도·통신·위협 모델의 절충이 있습니다. 보안 세부는 별도 원문 확인 범위입니다.

구조·비교·판단

구분	원리·특징	적용·주의
중앙 학습	원자료를 모아 최적화	자료 이동·보호 부담
FedSGD	로컬 gradient 집계	통신 빈도 큼
FedAvg	여러 지역 학습 뒤 가중 평균	통신 감소·client drift

적용 예제

FedAvg 표본 가중 평균

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: A기관은 100명, B기관은 300명의 자료로 같은 파라미터를 학습했습니다. 학습 결과는 각각 2와 4입니다.

1. 전체 표본 수는 400이고 가중치는 A 1/4, B 3/4입니다.

2. 서버의 가중 평균은 (100×2+300×4)/400=3.5입니다. 두 기관에 같은 가중치를 주면 평균은 3입니다.

3. 새 모델을 배포하고 기관별 holdout 성능을 봅니다. 큰 기관의 평균 개선이 작은 기관의 악화를 숨길 수 있습니다.

결과·해석: 집계의 분모·표본 가중치와 참여자별 성능 관리가 중요합니다.

전제·주의: 서로 다른 파라미터 구조를 단순 평균하거나 표본 수 공개가 언제나 허용된다고 가정하지 않습니다.

답안 골격과 혼동 방지

정의·중앙 대비 → 배포→지역학습→집계 → FedSGD/FedAvg → 가중 평균 계산 → non-IID·통신·보호 한계

- 원자료 비이동을 완전한 프라이버시 보장으로 쓰지 않습니다.
- 각 기관에 동일 가중치와 표본수 가중치를 섞지 않습니다.

내용을 가리고 회상

1. FedAvg의 가중치 분모는 무엇입니까?

2. local epoch가 많아지면 통신과 drift는 어떻게 변할 수 있습니까?

3. secure aggregation과 DP는 같은 보장입니까?

적용 기준과 근거

FedAvg 원 논문 초록과 집계 원리를 확인했습니다. FedProx/secure aggregation/DP 등 개별 알고리즘의 보장·공격 모델은 별도 1차 원문 미확인으로 부분 처리합니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

• Communication-Efficient Learning of Deep Networks from Decentralized Data - H. Brendan McMahan 외 / Google 연구진; 2016 제출, AISTATS 2017; 2023-01-26 v4; 확인 2026-11-05.