FINE-TUNING-RLHF-RAFT

Fine-tuning·RLHF·RAFT 파이프라인

연관 기출 · 139-2-2

한눈에 이해

새 문서를 그때그때 보여 주는 RAG와 반복 업무의 행동을 가중치로 익히게 하는 fine-tuning은 역할이 다릅니다. 사람의 선호를 배우는 RLHF와 문서에서 근거를 고르는 법을 배우는 RAFT도 목적이 다릅니다.

정의와 핵심 원리

Fine-tuning은 사전학습 모델의 파라미터를 추가 자료로 조정하며 RLHF는 인간 선호 보상으로 정책을 최적화하고 RAFT는 도메인 RAG 문맥을 읽는 지도학습 데이터 구성법입니다.

• SFT는 입력-바람직한 출력 쌍으로 조건부 언어모델 손실을 줄여 형식·업무 스타일·과업 행동을 학습합니다. RAG는 외부 색인·문맥 갱신으로 지식을 공급하므로 둘을 결합할 수 있습니다. 가중치에 지식을 넣으면 삭제·최신성·근거 추적이 더 어려울 수 있습니다.

• InstructGPT의 RLHF는 시범 응답 수집→SFT→모델 출력 쌍의 인간 순위→reward model 학습→PPO 등으로 보상과 기준모델 이탈을 고려해 정책 최적화→독립 평가입니다. 보상 모형의 편향·reward hacking·선호/사실의 차이를 점검합니다.

• RAFT는 질문·golden/방해 문서·근거를 인용한 응답을 만들어 SFT하고 시험 때 RAG 문맥을 제공합니다. 원 논문은 일부 표본에서 golden 문서를 제외하는 구성도 사용합니다. RLHF와 달리 선호 순위→보상모형→RL이 필수 단계가 아니며 도메인 open-book 적응이지 일반적 가치 정렬과 동의어가 아닙니다.

구조·비교·판단

구분	원리·특징	적용·주의
RAG	질의 시 외부 문서 공급	지식 갱신·근거 제공
RLHF	선호→보상모형→정책 최적화	행동 정렬·보상 오류
RAFT	관련/방해 문서+근거 응답의 SFT	도메인 근거 읽기 적응

적용 예제

사내 규정 QA 개선

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 같은 질문에 현행 규정과 구 규정/무관 문서가 섞여 검색됩니다.

1. RAG로 문서 날짜·관련 절을 공급하고 최신 문서가 검색되는지 먼저 확인합니다.

2. RAFT 자료에는 질문·정답 근거·방해 문서·근거 응답을 넣어 방해를 무시하는 행동을 학습시킵니다.

3. 정중함·유용성 선호를 개선하려면 별도의 선호 라벨·RLHF 절차를 검토하고 사실 정확도는 독립 정답으로 평가합니다.

결과·해석: 검색·가중치 학습·선호 정렬의 실패 원인을 분리해 개선할 수 있습니다.

전제·주의: 공개 규정이 바뀌었다고 fine-tuning만 반복하면 검색 최신성 문제가 남을 수 있습니다.

답안 골격과 혼동 방지

FT/RAG 역할 → RLHF 단계 도식 → RAFT 자료·SFT 단계 → 학습 신호·목표 비교 → 평가·최신성·비용

- RAFT를 강화학습 알고리즘이라고 쓰지 않습니다.
- 인간 선호 보상이 사실 정확성과 항상 같다고 하지 않습니다.

내용을 가리고 회상

1. RLHF에서 reward model 학습 자료는 무엇입니까?

2. RAFT의 distractor를 넣는 목적은 무엇입니까?

3. RAG와 FT를 결합할 업무 조건은 무엇입니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Training language models to follow instructions with human feedback - Long Ouyang 외; 2022-03-04 v1; 확인 2026-11-05.
- RAFT: Adapting Language Model to Domain Specific RAG - Tianjun Zhang 외 / UC Berkeley 연구진; 2024-06-05 v2; 확인 2026-11-05.
- Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks - Patrick Lewis 외; 2021-04-12 v4; NeurIPS 2020; 확인 2026-11-05.