GRAPH-NEURAL-NETWORK

GNN의 메시지 전달과 관계 기반 예측

연관 기출 · 137-1-5, 139-4-5

한눈에 이해

한 변전소의 수요는 자기 센서만이 아니라 연결된 지점의 부하와도 관련될 수 있습니다. GNN은 각 점의 특징과 주변 연결 정보를 반복 섞어 관계를 반영한 표현을 만듭니다.

정의와 핵심 원리

노드·엣지·그래프의 특징과 연결 구조를 이용해 표현을 학습하고 분류·회귀·연결 예측 등을 수행하는 신경망 계열입니다.

• 입력은 노드 특징 X, 인접 구조 A, 필요 시 엣지 특징·시간 정보입니다. message passing은 이웃별 메시지 생성→순서에 불변인 합/평균/attention 집계→자기 표현과 결합/갱신을 반복합니다. k층은 대체로 k-hop 주변 정보를 섞으므로 너무 깊으면 과도한 평활·정보 압축 문제가 생길 수 있습니다.

• GCN은 대표적으로 H^(l+1)=σ(D̃^(−1/2)ÃD̃^(−1/2)H^lW^l), Ã=A+I로 자기 연결을 포함합니다. GNN 전체를 GCN 하나와 동일시하지 않고 GAT의 이웃 가중·GraphSAGE의 표본/집계 등 변형은 목표와 규모에 따라 선택합니다.

• VPP 수요예측은 노드=발전/저장/부하 지점, 엣지=전력망 또는 검증된 상관 관계, 노드특징=과거수요·기온·SOC로 구성할 수 있습니다. 시간 모델과 결합해 공간·시간 의존을 학습하되 임의 상관 엣지를 물리 인과로 해석하지 않습니다. 새로운 노드·그래프 변화·시간 누출·집계 비용을 검증합니다.

구조·비교·판단

구분	원리·특징	적용·주의
MLP	각 표본 특징 중심	연결 구조를 별도로 넣어야 함
CNN	규칙 격자의 국소 이웃	영상·고정 패턴
GNN	불규칙 그래프의 이웃 집계	관계·차수·동적 구조

적용 예제

이웃 평균 집계

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 노드A 특징2, 이웃B 특징4, 이웃C 특징6이며 자기 자신까지 같은 가중 평균합니다.

1. 집계값은(2+4+6)/3=4입니다.

2. 이 값에 학습 가중치와 비선형을 적용해 다음 표현을 만듭니다.

3. 실제 GCN의 대칭 차수 정규화는 이 단순 평균과 다를 수 있으므로 예제와 정식 모델을 구분합니다.

결과·해석: 연결과 특징이 함께 표현을 바꾸는 원리를 작은 그래프로 설명할 수 있습니다.

전제·주의: 같은 이웃 multiset이면 집계가 같도록 설계하는 이유는 노드 나열 순서가 의미를 바꾸면 안 되기 때문입니다.

답안 골격과 혼동 방지

정의·노드/엣지/X/A → 메시지→집계→갱신 → GCN 식·자기 연결 → VPP 예시 → 과평활·규모·해석 한계

- 관계가 있다는 사실만으로 인과를 확정하지 않습니다.
- 단순 평균 예제를 GCN 정규화 식의 정확 계산이라고 쓰지 않습니다.

내용을 가리고 회상

1. 노드 번호 순서를 바꾸어도 결과가 일관되어야 하는 이유는 무엇입니까?

2. k층의 수용 범위는 무엇과 관련됩니까?

3. VPP 엣지는 어떤 근거로 정의하겠습니까?

적용 기준과 근거

GCN 원 논문 초록의 그래프 구조·노드 특징 표현 학습을 확인했습니다. 수식·GAT/GraphSAGE 상세는 논문 본문 추가 확인 대상이며 VPP는 강사 설계입니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

• Semi-Supervised Classification with Graph Convolutional Networks - Thomas N. Kipf, Max Welling; 2017-02-22 v4, ICLR 2017; 확인 2026-11-05.