ON-DEVICE-AI

온디바이스 AI의 경량화와 실행

연관 기출 · 127-2-4

한눈에 이해

휴대기기가 음성을 직접 인식하면 네트워크가 끊겨도 동작할 수 있습니다. 기기의 메모리·전력·발열 한계를 고려해 모델을 줄이고, 실제 기기에서 지연과 정확도를 측정합니다.

정의와 핵심 원리

추론 또는 일부 학습을 사용자 기기/엣지의 연산 자원에서 수행하여 지연·연결 의존·원자료 이동을 줄이는 AI 실행 방식입니다.

• 하드웨어는 CPU·GPU·DSP/NPU·메모리·센서·전력/열 제어, 소프트웨어는 학습 모델·변환/최적화·runtime·가속 delegate·입출력 전처리로 구성합니다. 모델 연산자와 가속기 지원이 맞지 않으면 일부가 CPU로 돌아가 예상 이득이 사라질 수 있습니다.

• 경량화는 quantization(정밀도 축소), pruning(가중치/구조 희소화), distillation(교사 행동을 학생 모델에 학습), 효율적 구조·연산 fusion·캐시 등을 검토합니다. PTQ는 학습 후 변환, QAT는 학습 중 양자화 영향을 반영하며 실제 기기의 지원 정수 연산·보정 데이터·정확도 변화가 중요합니다.

• 효과는 낮은 왕복 지연·오프라인 동작·원자료 외부 이동 감소·클라우드 비용 절감 가능성입니다. 한계는 모델 크기·배터리·발열·기기 이질성·업데이트·관측·가중치 노출입니다. 일부 과업만 로컬·어려운 요청은 서버로 보내는 hybrid도 가능하며 개인정보 보호는 로컬 실행만으로 완결되지 않습니다.

구조·비교·판단

구분	원리·특징	적용·주의
Cloud AI	큰 자원·중앙 갱신	네트워크·전송·비용
On-device	기기 내 빠른 추론	메모리·전력·지원 연산자
Hybrid	로컬/서버 과업 분담	전송 기준·일관성·오프라인

적용 예제

모델 크기 계산

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 가중치 100만 개를 FP32에서 INT8로 바꾼다고 가정합니다.

1. 가중치 값만 저장할 때 FP32는 100만×4바이트=4MB, INT8은 100만×1바이트=1MB입니다.

2. 가중치 저장량은 4분의 1입니다. 전체 메모리 사용량을 계산하려면 스케일·영점 정보와 실행 환경, 활성값, 캐시를 포함해야 합니다.

3. 실기기에서 정확도·p95 지연·배터리·열·미지원 연산의 CPU fallback을 확인합니다.

결과·해석: 파일 크기 감소와 전체 메모리/서비스 속도 개선을 구분할 수 있습니다.

전제·주의: 양자화가 곧 양자 컴퓨팅이라는 뜻이 아니며 모든 연산이 4배 빨라지지 않습니다.

답안 골격과 혼동 방지

정의·배경 → HW/SW 구조 → 경량화·runtime → 효과·제약 → 실기기 평가·hybrid

- 로컬 AI를 학습이 항상 기기에서 일어나는 것으로 정의하지 않습니다.
- 메모리 감소율을 지연 감소율로 바로 바꾸지 않습니다.

내용을 가리고 회상

1. NPU fallback은 왜 성능에 영향을 줍니까?

2. FP32→INT8의 원시 가중치 크기는 어떻게 바뀝니까?

3. 로컬/서버 분담 기준에 무엇을 넣겠습니까?

적용 기준과 근거

LiteRT 공식 문서의 PTQ·가속 HW·자원 제약 확인. pruning/distillation/QAT 개별 원 알고리즘과 제품별 지원 범위는 추가 확인 대상입니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Model optimization, Google AI Edge LiteRT - Google AI Edge; 문서 날짜 미표시; 2026-11-05 확인; 확인 2026-11-05.