OUTLIERS-NOISE-BIAS-FILTERING

이상치·노이즈·편향과 처리 판단

연관 기출 · 136-3-4, 139-3-2, 139-4-1

한눈에 이해

폭염 날 전력사용량 급증은 중요한 사건일 수 있지만 센서 단선의 큰 값은 측정 오류일 수 있습니다. 값이 크다는 이유만으로 지우면 드문 고장 신호를 잃습니다.

정의와 핵심 원리

이상치는 정상으로 기대한 패턴에서 벗어난 관측이며 노이즈는 원 신호를 흐리는 우연 오차, 편향은 수집·측정·모형에서 체계적으로 치우치는 성질입니다.

• 전역 이상은 전체 분포에서 극단적인 점, 맥락 이상은 시간·장소·상태를 고려할 때 비정상인 점, 집단 이상은 개별 값보다 연속 구간/조합이 비정상인 경우입니다. 고장 탐지가 목적이면 이상치를 보존·라벨링할 수 있고 입력 오류이면 원인을 교정합니다.

• 탐지는 IQR·z/강건 점수·밀도(LOF/DBSCAN)·분리(IsolationForest)·예측/재구성 잔차로 할 수 있습니다. 필터링은 범위·형식·업무 조건·주파수/시간 평활 등 목적별 방법이며 통과·제외 조건과 원본을 남깁니다. 기준은 학습 자료에 맞추고 미래 자료를 보고 뒤늦게 조정한 시험 결과와 구분합니다.

• 이상치는 평균·분산·회귀 계수·거리/군집을 흔들 수 있고 편향은 특정 집단의 체계적 오차를 만듭니다. 처리에는 재측정·오류 교정·강건 추정·변환·대체·분리 모델·유지와 경고가 있으며 무조건 삭제는 해법이 아닙니다. 전처리 전후 분포·집단별 성능·오탐/미탐 비용을 비교합니다.

구조·비교·판단

구분	원리·특징	적용·주의
이상치	기대 패턴에서 이탈	사건·오류 모두 가능
노이즈	신호를 흐리는 오차	측정·전송 원인 점검
편향	체계적인 방향의 치우침	표집·측정·모형 각각 진단

적용 예제

전력계 이상 판정

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 새벽 전력이 100kW라면 공장 휴무일에는 높지만, 정상 생산일에는 평소 수준일 수 있습니다.

1. 전체 IQR만으로 판정하지 않고 요일·가동상태·기온을 맥락으로 넣습니다.

2. 여러 번 측정한 값이 100kW에 고정되면 센서값이 멈췄는지, 실제로 부하가 일정했는지 확인합니다.

3. 원본·제외 사유를 보존하고 강건 모델/교정 후 정상·고장 집단의 성능을 다시 측정합니다.

결과·해석: 이상하다고 표시한 값을 바로 지우지 않습니다. 원인이 센서 오류라면 교정하고, 실제 고장 신호라면 보존합니다.

전제·주의: 모든 이상치를 노이즈로 지우면 사기·고장처럼 희귀하지만 중요한 양성이 사라집니다.

답안 골격과 혼동 방지

정의·3종 이상 → 노이즈·편향 비교 → 통계/밀도/분리/잔차 → 처리 대안·필터링 → 영향과 전후 검증

- 3σ 밖을 무조건 오류로 단정하지 않습니다.
- 편향된 자료를 단순 표준화만으로 고쳤다고 하지 않습니다.

내용을 가리고 회상

1. 맥락 이상과 전역 이상의 차이는 무엇입니까?

2. 이상치가 중요한 정답인 문제는 어떤 것입니까?

3. 삭제·대체 전에 무엇을 기록해야 합니까?

적용 기준과 근거

탐지 알고리즘과 일반 품질 관리 근거를 확인했습니다. 전역/맥락/집단 분류와 필터링 범위는 질문 문맥에 맞춘 강사 정리입니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- scikit-learn: Novelty and Outlier Detection - scikit-learn developers; 1.9.1 표시; 확인 2026-11-05.
- Data quality use cases - Great Expectations; GX 1.23.2 표시; 확인 2026-11-05.