REGRESSION-ASSUMPTIONS

회귀의 등분산성과 다중공선성

연관 기출 · 132-1-11, 135-2-3

한눈에 이해

매출이 큰 점포일수록 예측 오차의 폭도 커지거나, 면적을 제곱미터와 평 두 컬럼으로 넣으면 계수 해석이 불안정할 수 있습니다. 오차의 성질과 입력들 사이의 관계는 다른 문제입니다.

정의와 핵심 원리

등분산성은 입력 조건에서 오차 분산이 일정한 성질이며 다중공선성은 설명변수들 사이에 강한 선형종속 또는 근사 선형종속이 있는 상태입니다.

• 회귀 $y=X\beta+\varepsilon$에서 대표 가정은 $E[\varepsilon|X]=0$, 적절한 모형·독립 오차와 $Var(\varepsilon|X)=\sigma^2 I$입니다. 등분산 위반 시 고전 표준오차·검정/구간이 부정확해질 수 있으나 외생성이 유지되면 OLS 계수가 곧바로 편향되는 것은 아닙니다. 잔차-적합값의 부채꼴 모양과 시간 패턴을 봅니다.

• 공선성은 X^TX를 특이/근사 특이하게 하여 계수의 분산을 키우고 자료 작은 변화에 계수 부호·크기가 흔들리게 합니다. $VIF_j=1/(1-R_j^2)$에서 R_j^2는 x_j를 나머지 X로 설명한 결정계수입니다. 단일 상관계수만으로 다변수 공선성을 모두 탐지할 수는 없습니다.

• 이분산은 변환·가중최소제곱·강건 표준오차 등을 목적에 맞게 검토하고, 공선성은 중복 변수 제거·도메인 통합·자료 확장·PCA·Ridge 같은 규제를 고려합니다. 변수 제거는 업무 의미·교란 통제 목적을 훼손할 수 있고 규제는 편향을 도입하므로 예측과 인과 해석의 목적을 구분합니다.

구조·비교·판단

구분	원리·특징	적용·주의
이분산	오차 폭이 X에 따라 변화	잔차 그림·강건 추론
다중공선성	X들 사이의 근사 선형종속	계수 불안정·VIF
대응 선택	변환/가중 또는 변수·규제	문제 원인별로 다름

적용 예제

면적 단위 중복

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 점포 면적을 m^2와 평 두 컬럼으로 함께 입력합니다.

1. 평 ≈ m^2/3.3058이면 두 열이 거의 같은 선형 정보를 가져 계수 조합을 구별하기 어렵습니다.

2. 한 단위로 통일하거나 업무상 의미 있는 파생 변수를 재설계합니다.

3. 잔차 폭이 매출 규모와 함께 커지면 이 문제는 별도의 이분산으로 진단하고 검정/예측 구간을 재평가합니다.

결과·해석: 공선성 조치와 오차 분산 조치는 서로 대체하지 않습니다.

전제·주의: VIF 임계값은 상황별 경험 기준이지 모든 분석을 판정하는 절대 법칙이 아닙니다.

답안 골격과 혼동 방지

가정·정의 → 영향·진단 → 이분산/공선성 비교 → 중복 단위 예 → 대응·목적별 한계

- 등분산은 종속변수 y의 분산이 모든 곳에서 같다는 말이 아닙니다.
- 공선성을 과적합과 완전히 같은 개념으로 쓰지 않습니다.

내용을 가리고 회상

1. VIF 식의 R^2는 어떤 회귀에서 구합니까?

2. 이분산이면 OLS가 항상 편향됩니까?

3. Ridge가 공선성에 도움을 주는 대가는 무엇입니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- scikit-learn: Linear Models - scikit-learn developers; 1.9.1 표시; 확인 2026-11-05.
- NIST/SEMATECH e-Handbook: Check of assumptions - NIST / SEMATECH; 웹판 날짜 미표시; 확인 2026-11-05.