REINFORCEMENT-LEARNING

강화학습의 상태·행동·보상과 VPP

연관 기출 · 139-4-5

한눈에 이해

수요를 맞히는 모델과 배터리를 언제 충전할지 결정하는 모델은 목표가 다릅니다. 강화학습은 행동이 다음 상태와 이후 보상에 주는 영향을 보고 누적 성과가 좋은 정책을 배웁니다.

정의와 핵심 원리

에이전트가 환경과 상호작용하며 상태에서 행동을 선택하고 보상을 받아 할인 누적 보상을 최대화하는 정책을 학습하는 방법입니다.

• MDP는 상태 S·행동 A·전이 P·보상 R·할인율 γ로 기술합니다. 반환 $G_t=\Sigma\gamma^k r_{t+k+1}$이며 정책 π(a|s)는 행동 선택 규칙입니다. 관측이 상태를 충분히 표현하지 못하면 부분 관측·이력/추정 상태를 고려합니다.

• Q-learning은 상태 s에서 행동 a를 고를 때의 가치 Q(s,a)를 갱신합니다. 목표값 $r+\gamma\max_{a'}Q(s',a')$와 현재 값의 차이가 TD 오차입니다. DQN은 신경망으로 Q를 추정하고 경험 재생과 목표 신경망을 이용합니다. 정책 기울기·액터-크리틱은 행동을 고르는 정책을 직접 학습합니다. 탐험과 활용, on-policy와 off-policy는 따로 구분합니다.

• 가상 발전소(VPP)에서는 부하·태양광 예측, 가격, 배터리 충전 상태(SOC)를 상태로 볼 수 있습니다. 행동은 충전 또는 방전, 보상은 절감한 비용에서 배터리 열화와 제약 위반 비용을 뺀 값으로 설계할 수 있습니다. 충전 한계와 안전 조건은 별도로 지키고 시뮬레이션과 제한된 실증으로 검증합니다.

구조·비교·판단

구분	원리·특징	적용·주의
지도 예측	주어진 입력의 정답 맞히기	수요 예측
가치 기반 RL	행동별 장기 가치 학습	이산 행동·Q 함수
정책/actor-critic	정책과 가치 직접 학습	연속 제어·분산/안정성

적용 예제

Q값 갱신

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 현재 Q=5, 보상 r=2, 다음 최대Q=6, γ=0.9, 학습률 α=0.1입니다.

1. 즉시 보상 2에 다음 가치 6의 할인값을 더하면 목표는 2+0.9×6=7.4입니다.

2. TD 오차=7.4−5=2.4이고 Q_new=5+0.1×2.4=5.24입니다.

3. 이 값은 한 관측의 갱신이며 실제 최적 정책의 증명은 아닙니다. 종료 상태이면 다음 가치 항은 0으로 처리합니다.

결과·해석: 즉시 보상과 다음 상태의 장기 가치를 결합하는 이유가 드러납니다.

전제·주의: 실제 전력 설비에 미검증 탐험 행동을 그대로 실행하는 적용 예로 쓰지 않습니다.

답안 골격과 혼동 방지

MDP·누적 보상 → 에이전트-환경 루프 → Q/Bellman 계산 → VPP 상태·행동·보상 → 탐험·제약·시뮬레이션

- 보상을 단순 분류 정답 라벨과 동일시하지 않습니다.
- 할인율과 학습률의 역할을 섞지 않습니다.

내용을 가리고 회상

1. γ와 α는 각각 무엇을 조절합니까?

2. target7.4와 Q_new5.24를 재계산할 수 있습니까?

3. VPP 보상에 배터리 열화를 빠뜨리면 무엇이 달라집니까?

적용 기준과 근거

DQN·Bellman·TD 원리는 PyTorch 공식 튜토리얼 확인. VPP는 강사 가상 설계이며 actor-critic 세부 원문·전력 운영 실증을 확인한 것은 아닙니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Reinforcement Learning (DQN) Tutorial - PyTorch developers; 튜토리얼 2.15.0+cu132 표시; 확인 2026-11-05.