RETRIEVAL-AUGMENTED-GENERATION

RAG·Advanced/Modular와 하이브리드 검색

연관 기출 · 134-1-13, 139-1-3, 139-2-2, 140-1-6

한눈에 이해

모델이 외운 기억만 묻는 대신 최신 업무 문서를 찾아 책을 펴 놓고 답하게 합니다. 다만 책을 잘못 찾거나 근거를 무시하면 여전히 틀릴 수 있어 검색과 답변을 따로 평가합니다.

정의와 핵심 원리

RAG는 외부 검색 근거를 언어모델 문맥에 결합하여 응답을 생성하는 방법이며 모델 가중치를 바꾸는 fine-tuning과 다른 갱신 경로입니다.

• 오프라인은 문서 수집·권리/버전 확인→정제·chunk→embedding/색인·metadata 저장, 온라인은 query 해석→검색/필터→rerank·문맥 구성→근거 기반 생성·출처 제시로 구성합니다. chunk 경계·문서 날짜·접근 권한·중복·삭제 반영이 검색 품질을 좌우합니다.

• Gao 등의 분류에서 Naive는 index-retrieve-generate의 기본 구조, Advanced는 사전 query/index 최적화와 사후 reranking/문맥 정리로 보완하며 Modular는 검색·라우팅·반복·재작성 등 모듈을 과업에 맞게 조합합니다. Advanced와 Modular는 배타적 제품 등급이 아니라 저자의 설계 분류입니다.

• 하이브리드는 lexical(BM25 등)의 정확 용어/코드 일치와 vector의 의미 유사성을 결합합니다. RRF는 Σ1/(k+rank_i)로 서로 다른 순위를 합칠 수 있습니다. retrieval recall/precision·근거 적합성과 응답 정확/faithfulness·완결성·지연·비용을 분리 측정하며 답이 없는 질문은 근거 없음으로 처리합니다.

구조·비교·판단

구분	원리·특징	적용·주의
Lexical	어휘·정확 코드·역색인	동의어/표현 차이에 약할 수 있음
Vector	embedding 의미 유사성	수치·고유코드 exact match 보완 필요
Advanced·Modular	전후 개선/모듈 조합	반복 검색·라우팅은 비용 증가

적용 예제

매뉴얼의 E-42 오류 검색

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 사용자는 E-42 냉각 경보 해제 방법을 질문합니다.

1. lexical로 E-42 정확 문서를 찾고 vector로 냉각/과열 표현의 관련 절을 찾습니다.

2. 발행일·장비 모델을 필터하고 서로 다른 검색 순위를 결합한 후 실제 조항을 rerank합니다.

3. 선정 근거와 적용 모델을 포함해 답하고 검색 누락과 생성 오류를 별도 기록합니다.

결과·해석: 최신성은 색인 갱신에서, 답변의 근거 사용은 생성 평가에서 확인합니다.

전제·주의: RRF의 k는 군집 수가 아닌 순위 평활 상수이며 source별 점수를 확률처럼 더하지 않습니다.

답안 골격과 혼동 방지

RAG 정의·FT 비교 → offline/online 구조 → Advanced/Modular 표 → hybrid·RRF → 품질·날짜·권한·비용 평가

- RAG가 환각을 완전히 없앤다고 쓰지 않습니다.
- 검색된 문서에 있다는 사실만으로 기술 내용이 진실이라고 확정하지 않습니다.

내용을 가리고 회상

1. RAG에서 문서를 갱신하면 모델 가중치가 바뀝니까?

2. Advanced와 Modular는 어떤 설계 차이입니까?

3. lexical과 vector를 함께 쓰면 어떤 질문을 보완합니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks - Patrick Lewis 외; 2021-04-12 v4; NeurIPS 2020; 확인 2026-11-05.
- Retrieval-Augmented Generation for Large Language Models: A Survey - Yunfan Gao 외; 2024-03-27 v5; 확인 2026-11-05.
- Hybrid search using vectors and full-text search - Microsoft Azure AI Search; 문서 날짜 미표시; 2026-11-05 확인; 확인 2026-11-05.