SYNTHETIC-DATA-GENERATION-EVALUATION

합성데이터 생성과 품질 평가

연관 기출 · 140-3-3, 138-4-6

한눈에 이해

원본의 나이·매출 분포와 관계를 닮은 새 행을 만들면 학습·시험 자료를 보완할 수 있습니다. 단순히 비슷하게 보인다고 희귀 집단의 성능이나 원본 보호까지 확인된 것은 아닙니다.

정의와 핵심 원리

실제 현상을 모형·규칙·시뮬레이션·생성모형으로 모사하여 만든 인공 자료이며 통계 유사성·과업 효용·노출 위험을 별도로 평가해야 합니다.

• 생성에는 규칙·시뮬레이션, 통계 모형, VAE·GAN, 확산 모델·언어 모델 등을 쓸 수 있습니다. 필요한 데이터와 희귀 사례를 정한 뒤 실제 데이터를 학습용과 평가용(holdout)으로 나눕니다. 드문 고장이나 경계 사례는 조건부 생성이나 물리 시뮬레이션으로 보완할 수 있습니다.

• 품질은 유효 범위·PK/FK·논리 제약, 단변량 분포(KS·빈도 차이), 다변량 관계/상관·관계표 cardinality, coverage/다양성, downstream task 효용으로 나눕니다. Train-on-synthetic/Test-on-real로 실제 holdout 성능을 비교하며 분포가 닮았다는 점수만으로 업무 가치를 확정하지 않습니다.

• 과적합·원본 중복·근접도·속성/멤버십 추론 등 노출 위험을 함께 평가합니다. 원본과 똑같은 행이 없어도 민감한 패턴이 노출될 수 있습니다. 통계 위험 지표와 법적 익명성 판단은 별개이며 일반 합성 데이터가 차분 프라이버시 같은 수학적 보장을 자동 제공하지 않습니다.

구조·비교·판단

구분	원리·특징	적용·주의
충실도	원본 분포·관계 유사성	holdout·희귀 집단 확인
유용성	실제 과업의 성능·가치	TSTR 등 실제 시험 필요
노출 위험	복제·근접·추론 가능성	유사성과 상충 가능

적용 예제

연령·구매액 합성 자료

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 실제 자료 1만 행 중 2천 행은 평가용으로 남기고, 나머지 8천 행으로 생성기를 학습합니다. 생성기는 합성 자료 1만 행을 만듭니다.

1. 나이와 금액의 분포·상관·불가능 값·중복을 검사합니다.

2. 합성 자료로 학습한 수요 모델과 실제 학습용 자료로 학습한 기준 모델을 준비합니다. 두 모델의 오류를 같은 실제 평가용 자료에서 비교합니다.

3. 원본 train과 holdout에 대한 근접도 차이·민감 속성 노출을 점검하고 집단별 효용 차이를 보고합니다.

결과·해석: 그럴듯함·실용성·보호 성질을 다른 증거로 평가합니다.

전제·주의: 합성 생성법과 학습 범위·시드·평가 기준을 남겨 재현과 오류 추적이 가능하게 합니다.

답안 골격과 혼동 방지

정의·생성 유형 → 생성/분할 흐름 → 충실도·효용·노출 3축 → TSTR 사례 → 목적·제약·한계

- 통계 품질 점수 100%를 개인정보 보호 100%로 해석하지 않습니다.
- 생성기 학습에 실제 시험 holdout을 넣지 않습니다.

내용을 가리고 회상

1. 분포가 비슷한데 예측 성능은 낮을 수 있습니까?

2. TSTR의 test에는 어떤 자료를 씁니까?

3. 중복행이 없다는 사실만으로 보호를 보장할 수 있습니까?

적용 기준과 근거

평가 축·지표와 VAE 원리는 원 자료 확인. GAN/diffusion 등 생성법 전체의 원 논문 확인과 PET 법/보안 비교는 담당 범위 밖·추가 확인입니다.

내용 검토 상태: 부분 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- SDMetrics: Quality - DataCebo / SDV developers; 문서 날짜 미표시; 2026-11-05 확인; 확인 2026-11-05.
- SDMetrics: Privacy - DataCebo / SDV developers; 문서 날짜 미표시; 2026-11-05 확인; 확인 2026-11-05.
- Auto-Encoding Variational Bayes - Diederik P. Kingma, Max Welling; 2013 원 논문; 2022-12-10 v11; 확인 2026-11-05.
- Generative Adversarial Networks - Ian J. Goodfellow 외; 2014-06-10 v1; 확인 2026-11-05.