TEXT-MINING-OPINION-TFIDF

데이터·텍스트·오피니언 마이닝과 TF-IDF

연관 기출 · 129-3-3, 132-3-3

한눈에 이해

상품 후기에서 어떤 부품이 칭찬받는지 찾으려면 문장을 숫자로 표현하고 대상 속성·감정을 구별해야 합니다. 흔한 단어와 특정 문서에만 나오는 단어의 정보량을 달리 주는 것이 TF-IDF입니다.

정의와 핵심 원리

데이터 마이닝은 자료에서 유용한 패턴을 발견·검증하는 과정이며 텍스트 마이닝은 언어 자료, 오피니언 마이닝은 의견 대상·극성 등을 분석하는 과업입니다.

• 통계와 마이닝은 추론·예측·탐색 기법을 공유하므로 통계는 작은 자료/마이닝은 큰 자료처럼 배타적으로 나누지 않습니다. 정형은 사전 정의한 변수/표, 비정형은 텍스트·음성·영상에서 구조·특징을 추출해야 한다는 차이로 비교합니다.

• 텍스트는 목적→수집/정제→토큰화·형태소/표현→특징·모델→평가·활용으로 처리합니다. 오피니언은 제품 속성 추출→관련 의견·극성 판별→속성별 요약을 포함하며 부정·반어·대상별 혼합 감정을 주의합니다. 단순 빈도는 긍정/부정의 의미를 직접 설명하지 않습니다.

• 기본 TF-IDF(t,d)=TF(t,d)×log(N/DF(t))에서 DF는 해당 단어가1회 이상 나온 문서 수입니다. 132회는 주어진 log와 DF 가공 금지를 따라 smooth/+1/L2 normalization을 넣지 않습니다. 라이브러리는 idf+1·평활·정규화가 기본일 수 있어 옵션과 수식을 먼저 고정해야 합니다.

구조·비교·판단

구분	원리·특징	적용·주의
정형 마이닝	표·명시 변수	정제·스키마·통계
텍스트 마이닝	언어 표현에서 특징/패턴	토큰·문맥·평가
오피니언	대상 속성·의견·극성	반어·부정·혼합 감정

적용 예제

132회 TF-IDF 전 항목

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: N=3. TF(문서1,2,3): 엔진(15,10,10), 모터(3,0,0), 미션(3,5,3), 스티어링휠(0,5,1), 타이어(2,3,5). log(3/1)=.47, log(3/2)=.17, log(3/3)=0.

1. DF는 엔진3·모터1·미션3·스티어링휠2·타이어3입니다. TF 총합이 DF가 아닙니다.

2. 모터 문서1=3×.47=1.41, 스티어링휠 문서2=5×.17=.85, 문서3=1×.17=.17입니다.

3. 나머지는 TF0 또는 IDF0이라0입니다. 순서대로 D1=(0,1.41,0,0,0), D2=(0,0,0,.85,0), D3=(0,0,0,.17,0)입니다.

결과·해석: 3×5 행렬을 주어진 raw TF와 무평활 IDF로 재현했습니다.

전제·주의: 문제의 근사 log를 임의 정밀 log나 smoothing으로 바꾸면 지시한 결과와 달라집니다.

답안 골격과 혼동 방지

개념·통계와 겹침 → 정형/비정형 비교 → 의견분석 절차 → TF·DF·IDF 분모 → 원문 전체 계산·구현 차이

- 단어가 나온 총횟수를 DF로 쓰지 않습니다.
- 모든 문서에 나온 단어의 IDF0에 임의1을 더하지 않습니다.

내용을 가리고 회상

1. DF와 TF는 각각 무엇을 셉니까?

2. 스티어링휠의 DF2와 문서2 점수.85를 재계산할 수 있습니까?

3. 텍스트 마이닝 중 오피니언 마이닝이 추가로 찾는 정보는 무엇입니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- scikit-learn: Feature extraction - scikit-learn developers; 1.9.1 표시; 확인 2026-11-05.
- Mining and Summarizing Customer Reviews - Minqing Hu, Bing Liu / University of Illinois Chicago; KDD 2004; 확인 2026-11-05.