TRANSFORMER-MIXTURE-OF-EXPERTS

Transformer와 MoE의 결합

연관 기출 · 137-1-7

한눈에 이해

문장 안에서 어떤 단어를 참고할지 정하는 attention과 어떤 계산 전문가를 쓸지 정하는 routing은 다른 기능입니다. Transformer의 일부 계산층을 전문가 여러 개로 바꾸어 선택 실행할 수 있습니다.

정의와 핵심 원리

Transformer는 self-attention과 위치별 신경망을 중심으로 순서를 처리하는 구조이며 MoE는 입력별로 일부 전문가를 선택하는 조건부 계산 구조입니다.

• 입력 embedding·위치 정보에서 Q/K/V를 만들고 $\mathrm{Attention}(Q,K,V)=\mathrm{softmax}(QK^{T}/\sqrt{d_k})V$를 계산합니다. multi-head는 여러 투영 공간의 결과를 결합합니다. residual·normalization·FFN을 쌓으며 decoder의 causal mask는 미래 토큰을 가려 자기회귀 학습의 정보 누출을 막습니다.

• Dense FFN은 모든 토큰이 같은 가중치를 사용하지만 sparse MoE는 router가 토큰별 top-k 전문가를 선택하고 출력을 결합합니다. attention층과 MoE FFN은 한 모델에서 함께 쓸 수 있습니다. 전체 파라미터 수가 늘어도 토큰당 활성 연산량이 같은 비율로 늘지는 않습니다.

• MoE는 용량 확대와 계산 효율 가능성이 있으나 전문가 편중·capacity overflow·라우터 불안정·노드 간 all-to-all 통신·추론 배치효율·큰 메모리를 다뤄야 합니다. load balancing·전문가 배치·통신 최적화를 검토하며 Switch의 특정 실험 배속을 모든 모델의 비용 절감률로 일반화하지 않습니다.

• Q와 K 성분을 독립·평균0·분산1로 보는 설명용 가정에서는 내적의 분산이 d_k입니다. $\sqrt{d_k}$로 나누어 점수 크기를 안정화하고 큰 내적으로 인한 softmax 포화와 작은 기울기를 완화합니다.

구조·비교·판단

구분	원리·특징	적용·주의
Attention	입력 위치별 참조 가중	Q/K/V·mask·위치
Dense FFN	토큰마다 같은 계산층	단순 배치·모든 파라미터 활성
MoE FFN	router가 전문가 일부 선택	활성 연산·통신·편중 관리

적용 예제

전문가 두 명의 가중 결합

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: router가 토큰에 대해 E1 0.7, E2 0.3을 주고 출력이 각각[2,0],[0,4]라고 가정합니다.

1. top-2 결합 결과는0.7[2,0]+0.3[0,4]=[1.4,1.2]입니다.

2. top-1이면 하나만 실행하므로 정규화·capacity 정책에 따라 결과가 달라집니다.

3. expert 총개수·top-k·토큰 분배와 네트워크 비용을 함께 기록해야 모델 규모와 실제 계산량을 비교할 수 있습니다.

결과·해석: 전문가 선택은 여러 모델의 답을 사람이 투표하는 것과 다른 내부 계산입니다.

전제·주의: 예제 가중치는 교육용이며 특정 제품의 router 정규화 규칙을 가정하지 않습니다.

답안 골격과 혼동 방지

두 개념 정의·관계 → attention 식·mask → MoE routing 흐름 → 가중 결합 예시 → 연산/메모리/통신 절충

- Transformer와 MoE를 반드시 대체 관계로 쓰지 않습니다.
- 전체 파라미터 수를 매 토큰 계산량과 동일시하지 않습니다.

내용을 가리고 회상

1. QK^T 뒤 √d_k로 나누는 목적은 무엇입니까?

2. causal mask는 무엇을 막습니까?

3. 전문가가 늘어도 활성 계산과 메모리는 어떻게 다를 수 있습니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Attention Is All You Need - Ashish Vaswani 외; 2017 원 논문; 2023-08-02 v7; 확인 2026-11-05.
- Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity - William Fedus, Barret Zoph, Noam Shazeer; 2022-06-16 v3; 확인 2026-11-05.