TURBOQUANT-VECTOR-QUANTIZATION

TurboQuant와 KV 캐시 양자화

연관 기출 · 139-2-4

한눈에 이해

긴 대화의 이전 토큰 정보를 저장하는 KV 캐시가 커지면 메모리 이동이 병목이 됩니다. 숫자를 적은 비트로 저장하되 거리와 내적이 크게 망가지지 않게 하는 것이 핵심입니다.

정의와 핵심 원리

TurboQuant는 고차원 벡터·LLM KV 캐시를 낮은 비트 수로 압축하면서 오차·내적 추정을 다루는 Google Research의 양자화 기법입니다.

• 2026-03-24 연구 소개에서는 벡터를 무작위 회전한 뒤 PolarQuant 계열 방식으로 압축합니다. 이어 압축하고 남은 오차에 1비트 QJL을 적용해 내적 추정의 편향을 보완합니다. 이때 양자화는 숫자를 더 적은 비트로 표현하는 수치 압축입니다.

• 기존 block 양자화는 scale/normalization 등의 metadata가 유효 비트 수를 늘릴 수 있습니다. TurboQuant 계열은 데이터 독립적 변환과 알려진 기하 분포를 이용해 이런 overhead와 왜곡을 줄이려는 접근입니다. weight 압축·KV 압축·벡터 색인 압축을 같은 대상이라고 쓰지 않습니다.

• 연구팀은 지정 long-context 과업에서 3-bit KV와 최소 6배 KV 메모리 축소, H100에서 4-bit attention logits 커널이 FP32 key 대비 최대 8배라고 보고했습니다. 전체 서비스가 8배 빨라지거나 모든 모델의 정확도 손실이 0이라는 보장은 아닙니다. 모델·자료·길이·비트 수·kernel·기준 구현을 고정해 end-to-end 지연·정확도·메모리를 검증합니다.

구조·비교·판단

구분	원리·특징	적용·주의
일반 양자화	정밀도 축소+scale 등	metadata·왜곡·지원 kernel
TurboQuant	회전·주압축+QJL 잔차 보정	내적·KV·검색 실험
평가 구분	메모리/커널/end-to-end	보고 조건을 수치와 함께 기재

적용 예제

원시 저장 비트 계산

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: KV 캐시의 벡터 성분 100만 개를 FP32에서 3비트로 바꾼다고 가정합니다.

1. FP32는32,000,000bit=4,000,000byte입니다.

2. 3비트로 담은 값은 3,000,000비트=375,000바이트입니다. 값만 저장할 때 FP32의 저장량이 약 10.67배 큽니다.

3. 실제 캐시는 값 외에도 메타데이터와 정렬용 여분 공간을 사용합니다. 원시 저장량으로 구한 10.67배는 연구팀이 실험에서 보고한 최소 6배와 측정 범위가 다릅니다.

결과·해석: 명목 bit수·실제 메모리와 kernel 속도·서비스 속도의 차이를 분리합니다.

전제·주의: 생성 응답의 품질은 동일 과업과 출력 기준에서 별도로 검증합니다.

답안 골격과 혼동 방지

문제·압축 대상 → 두 단계 구조 → 기존 방식 차이 → 조건부 보고 성능 → 메모리 계산·실험 설계

- 최대 8배를 모든 LLM 처리량 향상으로 옮기지 않습니다.
- 3-bit payload 계산만으로 실제 메모리 절감률을 확정하지 않습니다.

내용을 가리고 회상

1. KV 압축과 weight 압축의 대상은 무엇입니까?

2. QJL 잔차 보정의 목적은 무엇입니까?

3. 왜 32/3과 실제 메모리 절감비가 다를 수 있습니까?

적용 기준과 근거

Google Research 2026-03-24 원 발표를 실제 확인했습니다. 수치는 연구팀의 특정 벤치마크·kernel 보고이며 독립 재현/최신 일반 제품 적용은 확인하지 않았습니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

• TurboQuant: Redefining AI efficiency with extreme compression - Amir Zandieh, Vahab Mirrokni / Google Research; 2026-03-24 Google Research 발표; 확인 2026-11-05.