VECTOR-ANN-HNSW-IVF

벡터 DB의 HNSW·IVF 검색

연관 기출 · 137-4-2

한눈에 이해

벡터가 수억 개면 매번 전부 거리를 계산하기 어렵습니다. 가까운 이웃으로 이어진 길을 따라가거나 공간을 먼저 여러 구역으로 나누어 필요한 구역만 뒤지는 방식으로 후보를 줄입니다.

정의와 핵심 원리

근사 최근접 탐색(ANN)은 정확도 일부와 계산/메모리를 절충하여 유사 벡터를 검색하며 HNSW는 계층 그래프, IVF는 coarse 구역의 역파일을 이용합니다.

• HNSW는 높은 층의 희소 연결로 큰 이동을 한 뒤 아래층의 촘촘한 이웃을 탐색합니다. M은 노드 연결 수, efConstruction은 구축 탐색 폭, efSearch는 질의 탐색 폭에 영향을 주며 커질수록 대체로 recall과 시간/메모리 비용이 증가합니다.

• IVF는 벡터를 학습한 중심점(centroid)에 따라 nlist개 구역으로 나누고 구역마다 벡터 목록을 저장합니다. 질의와 가까운 nprobe개 구역의 목록만 검색합니다. 실제 최근접 벡터가 다른 구역에 있으면 놓칠 수 있습니다. 구역마다 벡터 수가 달라 실제 검색량은 nprobe/nlist 비율과 다를 수 있습니다.

• 거리 척도 cosine/내적/L2·정규화·차원·필터·갱신/삭제·분산 운영을 일치시킵니다. 정확 flat 검색 결과를 기준으로 recall@k와 p95 지연·메모리·구축/갱신 비용을 측정합니다. PQ는 벡터 압축 방식이고 IVF/HNSW는 후보 탐색 방식이라 결합 가능하며 같은 분류 축의 대안으로만 놓지 않습니다.

구조·비교·판단

구분	원리·특징	적용·주의
Flat	모든 후보와 정확 거리	기준 정답·작은 자료
HNSW	계층 근접 그래프 탐색	고recall/낮은 지연·메모리 부담
IVF	coarse 구역 선택 후 목록 검색	nlist/nprobe·학습·편향

적용 예제

IVF 탐색 범위

강사 생성 학습 예제입니다. 공식 기준답안이 아닙니다.

조건: 벡터 100만 개를 nlist=100개 구역에 고르게 두고 nprobe=5로 검색합니다.

1. 질의 벡터와 가까운 구역 5개를 선택해 목록에 있는 약 5만 개 벡터를 비교합니다.

2. nprobe=10이면 약 10만 개 벡터를 비교합니다. 더 많은 후보를 찾아 재현율이 높아질 수 있지만 시간이 더 걸립니다.

3. 실제 목록 길이는 다를 수 있으므로 실측 후보수·정확 top-k 대비 recall을 보고합니다.

결과·해석: 빠르다는 주장 대신 검색 범위·정확도·자원 비용의 절충을 설명합니다.

전제·주의: embedding 모델 버전이나 정규화를 바꾸면 저장 벡터/질의와 색인을 함께 재검증합니다.

답안 골격과 혼동 방지

벡터/ANN 정의 → HNSW 구축·계층 탐색 → IVF 분할·역파일 → 파라미터 비교 → recall·지연·메모리 검증

- IVF는 모든 목록을 자동 검색한다고 쓰지 않습니다.
- Faiss의 특정 삭제 제약을 모든 HNSW 구현에 일반화하지 않습니다.

내용을 가리고 회상

1. M과 efSearch는 각각 어떤 비용을 바꿉니까?

2. IVF가 실제 최근접 이웃을 놓치는 경우는 무엇입니까?

3. PQ와 IVF를 결합할 수 있는 이유는 무엇입니까?

적용 기준과 근거

2026-11-05 열람한 출처 범위의 강사 생성 설명·가상 예제입니다. 공식 기출 해설이 아닙니다.

내용 검토 상태: 출처 확인. 출처 확인은 공식 정답이나 학습 성취를 뜻하지 않습니다.

출처별 상세 열람 범위는 위키의 출처 기록에서 확인합니다.

- Faiss indexes - Meta / Faiss project; 2025-07-28 편집 표시; 확인 2026-11-05.